

Tarea Complementaria

PREGUNTA (1)

2) La idea del Bagging es entrenar múltiples modelos de predicción independientes utilizando diferentes muestras del dataset original. Luego, las predicciones individuales se combinan para obtener un resultado final más robusto.

Diferencias:

⇒ Entrenamiento: → Bagging: Los modelos se entrenan de forma paralela e independiente unos de otros.

Boosting: El entrenamiento es secuencial.

⇒ Objetivo: → Bagging: Busca reducir la varianza del modelo sin incrementar el sesgo.

Boosting: Busca reducir tanto el sesgo como la varianza transformando modelos simples en un modelo predictivo fuerte.

⇒ Riesgo Principal

Bagging: Rara vez sobreajuste más que sus modelos base individuales.

Boosting: Altamente susceptible al sobreajuste.

b) Dada la expresión:

$$\text{Var}(\bar{y}) = \left(\frac{1-\rho}{m} + \rho \right) \sigma^2$$

- ¿El bagging reduce principalmente el sesgo, la varianza o ambos?

Reduce principalmente la varianza. Al promediar los árboles, el sesgo permanece igual al de un solo árbol. Sin embargo, la dispersión de los errores individuales se atenúa mediante el promedio, logrando una predicción menos sensible a variaciones en los datos de entrenamiento.

- ¿Qué ocurre con $\text{Var}(\bar{y})$ cuando m aumenta?

A medida que m tiende al infinito, el término $\frac{1-\rho}{m}$ se aproxima a 0. Por lo tanto, la varianza del ensemble se reduce hasta el límite inferior dado por $\rho\sigma^2$.

- ¿Que ocurre si ρ es muy alto?

Si la correlación promedio entre predictores se acerca a 1, el término $\frac{1-\rho}{m}$ se anula y la varianza total del ensemble es aproximadamente igual a σ^2 . Es decir, promediar modelos que son idénticos no aporta nueva información, el ensemble pierde su ventaja y no logra reducir el error general.

- Efecto de Random Forest sobre ρ y la varianza

En cada nodo, Random Forest selecciona aleatoriamente un subconjunto de features y solo busca mejorar el split dentro de ese grupo. Esto fuerza a que los árboles generen estructuras diferentes, disminuyendo ρ entre ellos. Al reducir ρ , el límite inferior de varianza se hace mucho menor, logrando que el ensemble reduzca su varianza global.

c) Error out of Bag (OOB)

El OOB es una métrica de validación interna, para evaluar qué tan bueno es un modelo de Random Forest sin necesidad de separar datos adicionales para pruebas, se calcula usando los datos que cada árbol no vio durante su entrenamiento. Como esos datos son nuevos para ese árbol en cuestión, sirven como test que permite predecir la precisión del modelo sin desperdiciar información de sets de validación externos.

d) Explicación del resultado

Tras n extracciones, este resultado nos indica que aproximadamente el 36.8% de los datos originales quedan fuera del conjunto de entrenamiento de cualquier árbol.

Estos datos descartados constituyen las muestras "Out of Bag". Este resultado nos muestra por qué cada modelo se entrena solo con alrededor del 63.2% de las muestras.

Pregunta (2)

3) Construcción del árbol de decisión

① Análisis del nodo Root

Clase 0: 5 muestras (B, D, I, K, L)

Clase 1: 6 muestras (G, H, J, M, N, O)

Clase 2: 4 muestras (A, C, E, F)

$$Gini = 1 - \left(\left(\frac{5}{15} \right)^2 + \left(\frac{6}{15} \right)^2 + \left(\frac{4}{15} \right)^2 \right) = 1 - \frac{25+36+16}{225} = \frac{148}{225} \approx 0,658$$

Tomamos el threshold intermedio $X_1 \leq 4.3$ (Entre 4.1 de 6 y 4.5 de 4).
Rama izquierda ($X_1 \leq 4.3$): 6 muestras, todos clase 1. $Gini_{Izq} = 0$

Rama derecha ($X_1 > 4.3$): 9 muestras (5 clase 0, 4 de clase 2)

$$Gini_{derecha} = 1 - \left(\left(\frac{5}{9} \right)^2 + \left(\frac{4}{9} \right)^2 \right) = \frac{40}{81} \approx 0.494$$

Calculamos la reducción de impureza

$$\Delta Gini = 0.658 - \left(\frac{6}{15}(0) + \frac{9}{15}(0.494) \right) \approx 0.362$$

Este split maximiza el $\Delta Gini$ evitando el riesgo intermedio

② Nivel 1 (Split del Nodo derecho)

⇒ Se observa que $X_1 > 7.15$ corresponde a 2 pacientes de clase 0 (B, L).
Entonces el threshold $X_1 \leq 7.15$.

• Rama izquierda ($X_1 \leq 7.15$): 6 muestras (2 de clase 0, 4 de clase 2)

$$Gini_{Izq} = 1 - \left(\left(\frac{2}{6} \right)^2 + \left(\frac{4}{6} \right)^2 \right) = \frac{16}{36} \approx 0.444$$

• Rama derecha ($X_1 > 7.15$): 3 muestras, todos clase 0,

$$Gini_{derecha} = 0$$

• Reducción de impurezas.

$$\Delta Gini = 0.444 - \left(\frac{6}{9}(0.444) + \frac{3}{9}(0) \right) \approx 0.198$$

b) Análisis de las hojas del árbol.

Hoja 1 ($X_1 \leq 4.3$)

- # muestras: 6
- Distribución: 0 (clase 0), 6 (clase 1), 0 (clase 2)
- Clase predicha: 1 (Riesgo intermedio)
- Gini: 0

Hoja 2 ($4.3 < X_1 < 7.15$)

- # muestras: 6
- Distribución: 2 (clase 0), 0 (clase 1), 4 (clase 2)
- Clase predicha: 2 (Evento adverso)
- Gini: 0.444

Hoja 3 ($X_1 > 7.15$)

- # muestras: 3
- Distribución: 3 (clase 0), 0 (clase 1), 0 (clase 2)
- Clase predicha: 0 (sin evento)
- Gini: 0

c) Clasificación de nuevos parente.

→ Parente $X_2 = (4.1; -0.1; 2.2)^T$

Como $X_1 = 4.1 \leq 4.3 \rightarrow$ Rama izquierda.

Hoja terminal alcanzada: Hoja 1

clase predicha: 1

Probabilidad empírica $p(X, T)$:

$$p(c=0) = 0\%$$

$$p(c=1) = \frac{6}{6} = 100\%$$

$$p(c=2) = 0\%.$$

→ Parente $X_6 = (6.1; 0.4; 1.3)^T$

Como $X_1 = 6.1 > 4.3$ (va a la derecha), pero ≤ 7.15 (Izg.)

Hoja terminal alcanzada: Hoja 2

clase predicha: 2

Probabilidad Empírica: $p(c=0) = \frac{2}{6} \approx 33.3\%$

$$p(c=1) = 0\%$$

$$p(c=2) = \frac{4}{6} = 66.7\%$$

d) Prevención de sobreajustes en problemas biomédicos

Si no se limita la profundidad máxima, el algoritmo continuaría creando divisiones para separar la 2 muestra de clase 0 en la Hoja 2, hasta que todas las hojas tuvieran un índice Gini de 0.

Al limitar la profundidad, el árbol se ve obligado a detenerse y capturar los patrones más representativos. Aquí se sacrifica un poco la precisión para obtener reglas de decisión más interpretables y robustas al momento de clasificar nuevos pacientes.