

Tarea Complementaria 5

Pregunta 1

a)

Aplicar PCA / SVD en un entorno clínico donde se registran múltiples variables simultáneamente permite identificar los patrones principales subyacentes. En lugar de analizar cada señal por separado, PCA extrae componentes que resumen el comportamiento conjunto del paciente agrupando las señales que varían de la misma manera.

b)

El data set representa redundancia porque algunas variables pueden contener información repetida o correlacionada. Si observamos la columna de matriz X :

- Columna 1 y columna 2 tienen valores idénticos para todos los pacientes
- Columna 3 y columna 4 también son idénticas entre sí

Esto podría indicar redundancia, por lo que no se necesitan ambas señales para entender el estado del paciente, una sola basta.

c)

Sea $\sigma_1 = 7.35$ y $\sigma_2 = 5.10$

① $V_1 = \sigma_1^2 = 7.35^2 = 54.0225$

$V_2 = \sigma_2^2 = 5.1^2 = 26.01$

② Varianza Total:

$$V_{\text{total}} = V_1 + V_2 = 54.0225 + 26.01 = 80.0325$$

③ %

Componente 1: $\frac{54.0225}{80.0325} \cdot 100\% = 67.5\%$

Componente 2: $\frac{26.01}{80.0325} \cdot 100\% = 32.5\%$

d) Clasificación de Paciente Lucía

$$X_{Lucia} = [3 \quad 3 \quad 0 \quad 0]$$

Lucía se asocia más con el grupo de pacientes 1-3

¿? → Esto porque según el problema los pacientes 1-3 presentan un patrón predominante en señales 1 y 2, mientras que pacientes 4-6 presentan patrón en las señales 3 y 4. Lucía tiene valores activos únicamente en las dos primeras señales por lo que encaja mejor con el grupo de pacientes 1-3

e)

Es necesario estandarizar cuando las variables del dataset tienen magnitudes, escalas o unidades de medida muy diferentes.

Si no se estandariza, el algoritmo le dará demasiada importancia a las señales que tienen valores grandes por naturaleza.

Pregunta (2)

a) Minimiza J significa buscar la configuración de grupos donde los puntos estén lo más cerca posible de sus respectivos centroides. Es decir, busca crear clusters con señales dentro de un mismo grupo similares entre sí.

b) En un problema biomédico representa el paciente prototipo o el perfil promedio de un subgrupo específico.
Por ejemplo, en un grupo de alto riesgo cardiometabólico, el centroide podría representar los valores promedio de este grupo: Presión arterial promedio, Glucosa promedio, IMC promedio.

c) El K means coloca centroides de forma aleatoria, y luego los ajusta en cada iteración. Una mala ubicación inicial puede hacer que el algoritmo agrupe los datos de forma ineficiente. Es decir, el resultado depende de donde se iniciaron los centroides en el paso 0.

d) No, no lo garantiza.

El algoritmo solo se detiene cuando los centroides dejan de moverse. Si la inicialización aleatoria condiciona que el algoritmo quede atrapado en un mínimo local, se puede perder una distribución global mucho mejor no explorada con un J más bajo.

e) Dado que K-means no garantiza encontrar el mínimo global debido a su sensibilidad de inicialización, el parámetro $n_{\text{int}}=10$ le indica al algoritmo que ejecute el proceso completo 10 veces de forma independiente, compare los resultados y seleccione como modelo final aquel que haya logrado el valor más bajo de J .

f) Dado que cada punto en este espacio representa un tumor individual evaluado por variables que describen características celulares, el centroide de grupo el valor medio de todas estas características. Por lo que tiene sentido interpretarlo como el perfil morfológico promedio de este grupo tumoral.

g) Limitaciones:

1) Sensibilidad a valores atípicos (Outliers): Al minimizar la distancia al cuadrado en la función J , los errores grandes se penalizan desproporcionadamente. Es por esto que un solo outlier clínico puede jalar el centroide lejos del verdadero centro de masa del paciente.

2) Asumición de clústeres esféricos: K-means asume que los grupos tienen una forma esférica y una varianza similar en todas las direcciones. No obstante en medicina, las distribuciones de enfermedades son complejas lo que hace que K-means corte o divida mal los grupos reales.