

TAREA COMPLEMENTARIA 6

Problema 1

PARTE A

a) Descripción de procedimiento

- División de datos: El dataset completo de 120 pacientes se divide aleatoriamente en 5 particiones de igual tamaño
- Modelos entrenados: Se entrenan 5 modelos independientes
- Subconjunto de evaluación: En cada una de las 5 iteraciones, el modelo solo evalúa 1 fold específico
- Cálculo de error promedio: Al finalizar las iteraciones, se obtiene un error por cada partición evaluada. El error final es la media de los 5 valores.
- Distribución de pacientes por fold: Cada iteración utiliza 96 paciente para el entrenamiento y 24 para evaluación

b) Cálculo de error promedio y σ

$$e = \frac{0.12 + 0.15 + 0.11 + 0.18 + 0.14}{5} = \frac{0.7}{5} = 0.14$$

$$s = \sqrt{\frac{1}{4} [(0.12 - 0.14)^2 + (0.15 - 0.14)^2 + (0.11 - 0.14)^2 + (0.18 - 0.14)^2 + (0.14 - 0.14)^2]}$$

$$s = \sqrt{\frac{1}{4} [0.0004 + 0.0001 + 0.0009 + 0.0016 + 0]}$$

$$s = \sqrt{\frac{0.0030}{4}} = \sqrt{0.00075} \approx 0.0274$$

$$\text{Rpta: } 0.14 \pm 0.027$$

Un error del $14\% \pm 2.74\%$ nos dice que el modelo es sensible a la composición de las muestras. Es decir, no se operará con un tipo de error fijo, sino que dependerá de las características de la cohorte.

c) Corrección

- Entrenar el clasificador con dataset integro genera una expectativa de rendimiento desgracia. No habrá generalización.

- Esquema correcto

1) 80% train y 20% test

2) Validación cruzada sobre train

3) Entrenar con train

4) Evaluar modelo una vez más para determinar métricas de rendimiento

Parte B

d) Combinaciones posibles: $4 \times 4 = 16$

Iteraciones = 5

Calculo total = $16 \times 5 = 80$

e) Puede ser incorrecto porque solo se basa en exactitud. Tiene una varianza de 0.03; este valor denota sobreajuste

- Se debe integrar Regla de error estándar.

Problema 2

Parte A

3) Paso 1: Imputación: Llena valores faltantes. Usa Mediana / media
Fit: Solo sobre X-train.

Paso 2: Estandarización: Centra y escala características. Aprende Media y desviación estándar. Fit solo sobre X-train

Paso 3: Selección de features: Retiene variables predictivas. Aprende Importancia Coeficientes. Fit sobre X-train y Z-transformado

Paso 4: Random Forest: Genera predicción. Aprende Estructura de árboles
Fit: Sobre X-train y Z-transformado

b) Error crítico: Data leakage. Al calcular la mediana y aplicar escalado usando todo el dataset, se filtra información estadística.

c)

- Archivos: `app.py` y `pipeline.pkl` (modelo empaquetado)
- Carga: función `joblib.load()` (para instanciar modelo)
- Ingreso: `st.number_input()` para variables continuas y `st.select_box()` para categorías
- Predicción: `st.button()` recoge inputs como un array y llama a `modelo.predict_proba()`
- Resultado: `st.write()`

d)

- Sesgo del data set: Modelo pudo haber sido entrenado en una población diferente
- Mala calibración de probabilidades: El `stf` puede solo dar un `score` no calibrado
- Falta de validación externa: Sin evaluación prospectiva, no hay garantía que mantenga ese nivel de certeza.

e)

Estrategias de interpretabilidad

Valores SHAP: Cuantifica la contribución exacta de cada variable clínica

LIME: Genera un modelo local al rededor del perfil de datos para aproximar y explicar por qué el `random forest` tomó esa decisión.